

Ghaith SAIDANI

Ingénieur Data Science, MLOps & Data Engineering

ghaithx@hotmail.fr | 07 51 32 25 71 | France entière (Mobilité totale, Permis B) | github.com/Ghaith-Saidani
linkedin.com/in/ghaith-saidani | Français courant (C1) / Anglais courant (C1)

Profil : Élève ingénieur en double diplôme (3iL / ESPRIT), diplomation prévue en 2026, stagiaire PFE chez KBR. Spécialisé en Data Science, MLOps et Data Engineering : conception de pipelines distribués, serving conteneurisé (Docker, FastAPI, MLflow) et fiabilisation d'infrastructures décisionnelles. Mobilité acceptée sur toute la France.

COMPÉTENCES TECHNIQUES

- **Data Engineering / Stockage :** PostgreSQL, Neo4j, MongoDB, SQL avancé, modélisation dimensionnelle, Elasticsearch, Kibana, Redis, ETL/ELT, qualité des données.
- **MLOps / Cloud & DevOps :** Docker, Docker Compose, MLflow (Tracking & Registry), CI/CD (GitLab CI, GitHub Actions), FastAPI, Streamlit, Linux (Nginx, Bash), Git.
- **Machine Learning & IA :** PyTorch, Scikit-learn, LayoutLM, Qwen LLM, RAG, DDPM, VAE, ResNet-50, OpenCV, Tesseract OCR, Librosa, MTCNN, SMOTEENN.
- **Data Analytics / BI :** Power BI (DAX, Power Query), modélisation KPI métiers, reporting opérationnel & décisionnel, Excel avancé (TCD).
- **Programmation & Certifs :** Python (Pandas, NumPy), SQL, C/C++, Java, Qt/QML | NVIDIA DLI (NLP, Deep Learning), AWS Academy Cloud Foundations.

EXPÉRIENCE PROFESSIONNELLE

KBR

Juin 2026 – Présent

Stagiaire Data Engineer / Fullstack Data (PFE)

- Conception de l'architecture backend et data de la plateforme web sous **FastAPI** et **PostgreSQL** avec gestion sécurisée des flux d'authentification et endpoints API.
- Mise en place d'un pipeline d'ingestion des logs d'activité et flux d'utilisateurs vers **Elasticsearch** / **PostgreSQL** et intégration d'un moteur de recherche sémantique (**RAG** / **LLM**).
- Déploiement d'un tableau de bord de supervision **Power BI** pour l'analyse comportementale des KPI et conteneurisation complète sous **Docker** / **CI-CD**.

Starz Electronics

Janv. 2026 – Présent

Développeur Data / Infrastructure (Freelance)

- Développement d'une plateforme d'automatisation pour le contrôle/réconciliation des factures et la gestion des stocks en temps réel (**PostgreSQL**, **FastAPI**).
- Restructuration et sécurisation de l'infrastructure serveur Linux (**Nginx**, **Docker**, **backups automatisés Bash**), fiabilisant la continuité de service.

Capgemini Engineering

Juin 2025 – Août 2025

Stagiaire Data Scientist & Vision par Ordinateur

- Pipeline d'extraction automatique pour documents d'empreintes : prétraitement **OpenCV** / **Tesseract OCR** et fine-tuning **LayoutLM** / **Qwen LLM** supprimant la saisie manuelle.
- Conception d'un tableau de bord **Power BI** pour le monitoring des flux de traitement et la détection d'anomalies en méthodologie **Agile/Scrum**.

STMicroelectronics

Juil. 2024 – Août 2024

Stagiaire Développement Logiciel

- POC de migration logicielle de l'outil industriel **STM32CubeProgrammer** de Java/JavaFX vers **C++**, **Qt** et **QML** avec tests de non-régression et gains de performance bas-niveau.

FORMATION

- **3iL Ingénieurs (Limoges, France)** Sept. 2025 – prévu en 2026
Double diplôme : Manager Solution Digital et Data (MS2D)
- **ESPRIT (Tunis, Tunisie)** Sept. 2021 – prévu en 2026
Diplôme d'Ingénieur en Informatique, spécialisation Data Science ; accrédité CTI / EUR-ACE

PROJETS & RÉALISATIONS

Plateforme MLOps Churn Télécom – Serving & Monitoring

2026

Stack : MLflow, Docker Compose, FastAPI, Streamlit, Scikit-learn, SMOTEENN, GitLab CI

- Pipeline MLOps bout en bout : rééquilibrage de classes (**SMOTEENN**), Random Forest (**ROC-AUC 0.89**, **F1 0.84**) et gouvernance via **MLflow Model Registry**.
 - Serving et déploiement : API REST **FastAPI** (<45ms de latence) conteneurisée sous **Docker** avec dashboard d'inférence interactif **Streamlit**.
- #### Plateforme Due Diligence & Scoring Crypto – RAG & Graphes
- 2025
- Stack : NLP, RAG, LangChain, Neo4j, MTCNN, FastAPI, PostgreSQL, Streamlit*
- Audit automatique de projets crypto par parsing NLP de whitepapers, scraping financier multi-sources et cartographie d'entités via base graphe **Neo4j**.
 - Intégration d'un pipeline **RAG**, authentification biométrique (**MTCNN**) et génération automatique de fiches de synthèse de risque pour comités d'investissement.
- #### Génération Audio & Reconnaissance des Émotions Vocales (SER)
- 2025
- Stack : PyTorch, DDPM, VAE, ResNet-50, Librosa, EmoDB, RAVDESS*
- Pipeline d'augmentation acoustique par modèles génératifs (**DDPM**, **VAE**) sous **PyTorch** et extraction de Mel-spectrogrammes via **Librosa**.
 - Fine-tuning d'un classifieur profond **ResNet-50** sur corpus EmoDB et RAVDESS atteignant **86.4% d'Accuracy** avec forte robustesse aux bruits ambiants.